Actividad 5 | Gestión de datos, entrenamiento y MLflow

Informe técnico · Wisconsin Diagnostic Breast Cancer · Ejecución: 25 de octubre de 2026

1. Objetivo y fuente de datos

Se evaluaron dos algoritmos de clasificación binaria —regresión logística y random forest— para comparar desempeño, optimización y trazabilidad. Se empleó el dataset público Wisconsin Diagnostic Breast Cancer, distribuido mediante scikit-learn (basado en UCI): 569 registros, 30 atributos numéricos y una etiqueta diagnóstica. Es un ejercicio académico, no una herramienta clínica validada.

Diccionario y supuestos: las 30 variables corresponden a 10 medidas morfológicas (radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal), resumidas como media, error estándar y valor extremo («worst»). Se recodificó la etiqueta de origen (0 = maligno; 1 = benigno) a target_maligno: 1 = maligno y 0 = benigno. No hay identificadores ni validación hospitalaria independiente.

2. Preparación, versión y calidad

El análisis inicial encontró 0 valores nulos y 0 duplicados. Se eliminarían duplicados exactos si existieran, se normalizaron nombres de columnas y se guardaron archivos separados de datos originales y limpios en CSV (versión v1). Ambos archivos cuentan con huella SHA-256; la versión limpia es e096882d29158a1d… (completa en quality_report.json). No se imputó información ni se eliminaron valores extremos sin evidencia de error. El escalamiento se aplica solo dentro del pipeline de regresión logística durante entrenamiento y validación, lo que evita fuga de información.

Distribución: 357 benignos (62.7%) y 212 malignos (37.3%). Hay separación parcial en mean_radius y mean_concave_points, con zonas de solapamiento; la clase está moderadamente desbalanceada. El criterio IQR señaló 65 posibles valores atípicos de area_error, que se conservaron al poder corresponder a variabilidad biológica.

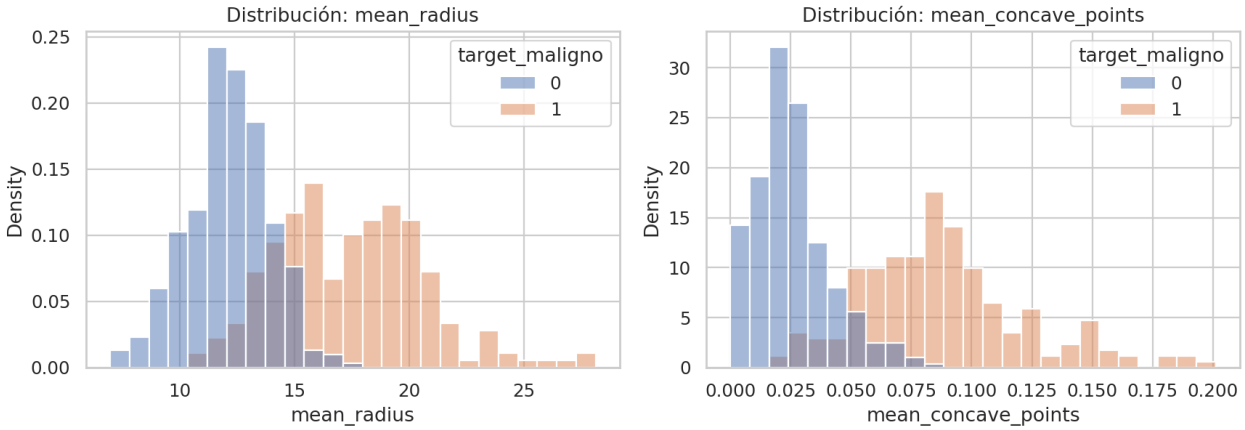


Figura 1. Distribuciones de dos atributos exploratorios por diagnóstico (0: benigno, 1: maligno).

3. Diseño de experimentos

División estratificada 80/20 (455 entrenamiento; 114 prueba), semilla 42. En el conjunto de entrenamiento se aplicó GridSearchCV con 5 pliegues estratificados, optimizando ROC-AUC: 6 combinaciones de regresión logística (C y class_weight) y 8 combinaciones de random forest (n_estimators, max_depth y min_samples_leaf). Los hiperparámetros se eligieron para balancear ajuste, complejidad y estabilidad, sin tocar el conjunto de prueba.

Resultados, evidencia y recomendaciones

4. Métricas y comparación estadística descriptiva

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	CV AUC ± DE
Regresión logística	0.9737	0.9756	0.9524	0.9639	0.9960	0.9959 ± 0.0046
Random forest	0.9649	1.0000	0.9048	0.9500	0.9940	0.9891 ± 0.0067

Los valores son del conjunto de prueba, salvo CV AUC (media y desviación estándar entre pliegues de validación). La diferencia descriptiva de ROC-AUC CV es 0.0068 a favor de regresión logística; los pliegues no constituyen réplicas independientes ni aportan una prueba formal de significancia. Debe evitarse afirmar superioridad estadística concluyente.

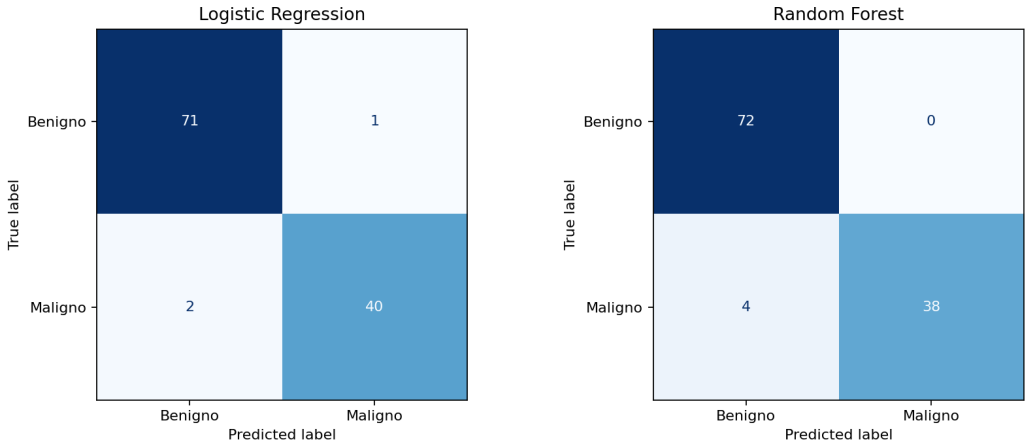


Figura 2. Matrices de confusión en prueba (verdaderos negativos/positivos y errores).

Regresión logística: TN = 71, FP = 1, FN = 2, TP = 40. Random forest: TN = 72, FP = 0, FN = 4, TP = 38. Aunque random forest obtuvo precisión perfecta, la regresión logística logró mejor recall de malignos (95.24% vs. 90.48%) y menor número de falsos negativos. Se selecciona regresión logística como referencia para este experimento, sin atribuirle utilidad clínica validada.

5. Trazabilidad con MLflow y reproducibilidad

Se configuró MLflow con SQLite y el experimento Actividad5_Comparacion_Modelos. Se verificaron dos runs FINISHED con parámetros, métricas, SHA-256 del dataset y modelos persistidos; los intentos duplicados de depuración se archivaron. La interfaz de Colab rechazó el encabezado del proxy (Invalid Host header), por lo que la evidencia de tracking se exportó mediante la API en mlflow_runs.csv y mlflow_details.txt. El error de visualización no interrumpió el almacenamiento de runs. Se conserva cuaderno, scripts, hashes, gráficos y configuraciones.

6. Deuda técnica, MLOps y limitaciones

Deuda técnica: conjunto pequeño y depurado, una sola división hold-out, ausencia de validación externa, evaluación limitada del desbalance, dependencia de versiones y seguimiento local efímero en Colab. Acciones: (1) fijar versiones y automatizar pruebas de calidad y CI; (2) realizar validación externa, intervalos por bootstrap y calibración; (3) definir umbral según costos de falsos negativos y falsos positivos; (4) establecer versionado centralizado, registro de modelos, monitoreo de deriva y retroalimentación; (5) aplicar auditoría de seguridad y análisis de sesgos antes de cualquier uso clínico.

Conclusión: el flujo cumple con limpieza, versionado básico, comparación reproducible y logging experimental. Los resultados son prometedores solo como demostración académica; no deben orientar diagnóstico ni reemplazar evaluación médica.

Referencias: scikit-learn, load_breast_cancer (documentación); UCI ML Repository, Breast Cancer Wisconsin (Diagnostic); MLflow, documentación de seguimiento de experimentos.