Christopher Raúl Gómez Álvarez

7183403

Gestión de Proyectos de Inteligencia Artificial

25-10-2026

Actividad 5

Objetivo y descripción del conjunto de datos

El objetivo de esta actividad fue implementar un flujo reproducible de aprendizaje automático que integrara preparación de datos, entrenamiento, optimización de hiperparámetros y seguimiento de experimentos mediante MLflow. Para ello, se compararon dos algoritmos de clasificación supervisada: regresión logística y Random Forest.

Se utilizó el conjunto público Wisconsin Diagnostic Breast Cancer, disponible en scikit-learn y originalmente documentado en el repositorio UCI Machine Learning. Contiene 569 observaciones, 30 variables predictoras numéricas y una variable objetivo que identifica lesiones benignas o malignas.

Las variables corresponden a diez características morfológicas: radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal. Cada característica se representa mediante valores promedio, error estándar y mediciones extremas.

Para facilitar la interpretación, se recodificó la variable objetivo como target_maligno, donde 1 representa casos malignos y 0 casos benignos.

El proyecto tiene fines exclusivamente académicos y no constituye un sistema de diagnóstico clínico validado.

Preparación, limpieza y versionamiento de datos

La exploración inicial permitió identificar las características generales y evaluar la calidad del conjunto de datos. Se obtuvieron los siguientes resultados:

- Observaciones originales: 569.
- Variables predictoras: 30.
- Valores faltantes: 0.
- Registros duplicados: 0.
- Casos benignos: 357 (62.7%).
- Casos malignos: 212 (37.3%).

Aunque no se encontraron registros duplicados ni valores faltantes, se implementaron procedimientos de validación y limpieza para asegurar consistencia y reproducibilidad. Se normalizaron los nombres de columnas y se conservaron versiones separadas del conjunto original y del conjunto procesado.

Los archivos se guardaron en formato CSV, identificados como versión v1, y se generaron huellas criptográficas SHA-256 para verificar su integridad. La versión limpia presenta una huella que comienza con e096882d29158a1d, documentada de manera completa en quality_report.json.

También se exploraron valores atípicos mediante el criterio de rango intercuartílico (IQR). La variable area_error presentó 65 observaciones potencialmente atípicas. Se decidió

conservarlas porque podrían representar variabilidad biológica legítima y no necesariamente errores.

En las distribuciones de mean_radius y mean_concave_points se identificaron diferencias entre clases, aunque con regiones de solapamiento. Asimismo, se observó un desbalance moderado entre casos benignos y malignos.

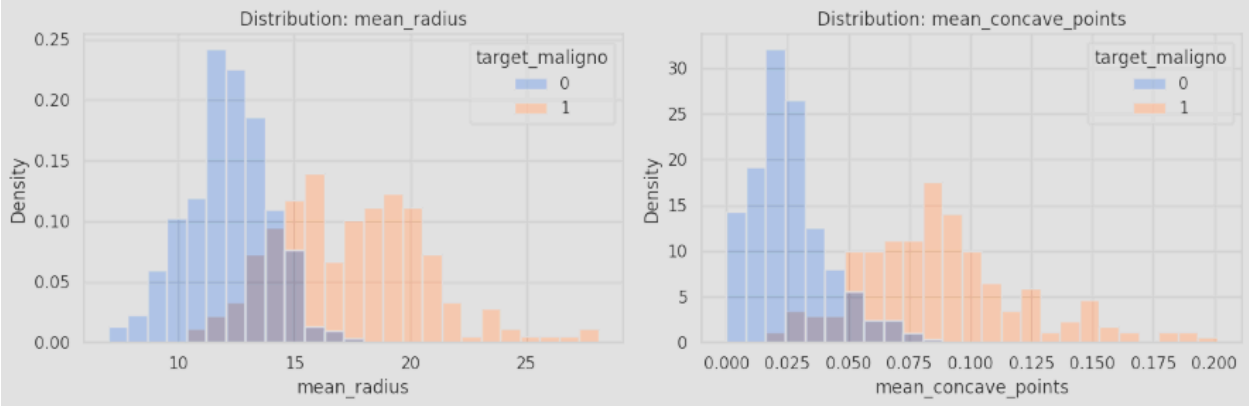


Figura 1. Distribución exploratoria de características morfológicas según el diagnóstico. Se identifican diferencias entre clases, aunque existe superposición de valores.

Para evitar fuga de información, la estandarización de variables se incorporó únicamente al pipeline de regresión logística, ajustándose durante el entrenamiento y la validación cruzada.

Entrenamiento y optimización de modelos

El conjunto se dividió mediante un procedimiento estratificado: 80% para entrenamiento (455 observaciones) y 20% para prueba (114 observaciones). Se estableció una semilla aleatoria de 42 para garantizar reproducibilidad.

Se entrenaron dos algoritmos:

- **Regresión logística:** se implementó un pipeline con StandardScaler y LogisticRegression. La búsqueda de hiperparámetros consideró seis combinaciones de regularización (C) y ponderación de clases (class_weight).
- **Random Forest:** se evaluaron ocho combinaciones de número de árboles (n_estimators), profundidad máxima (max_depth) y número mínimo de muestras por hoja (min_samples_leaf).

En ambos modelos se utilizó GridSearchCV con validación cruzada estratificada de cinco pliegues. La métrica principal de optimización fue ROC-AUC, debido a su capacidad para evaluar la discriminación entre clases considerando diferentes umbrales de clasificación.

El conjunto de prueba permaneció separado del proceso de ajuste, con el propósito de realizar una evaluación independiente de los datos utilizados para seleccionar los hiperparámetros.

Resultados y análisis comparativo

Los resultados obtenidos en el conjunto de prueba fueron los siguientes:

Métrica	Regresión logística	Random Forest
Accuracy	0.9737	0.9649
Precision	0.9756	1.0000
Recall	0.9524	0.9048
F1-score	0.9639	0.9500
ROC-AUC	0.9960	0.9940
ROC-AUC CV (media)	0.9959	0.9891
Desviación estándar CV	0.0046	0.0067

Ambos modelos presentaron un desempeño elevado. Sin embargo, la regresión logística obtuvo resultados superiores en accuracy, recall, F1-score y ROC-AUC.

La comparación de las matrices de confusión permitió identificar diferencias relevantes:

- **Regresión logística:** 71 verdaderos negativos, 1 falso positivo, 2 falsos negativos y 40 verdaderos positivos.
- **Random Forest:** 72 verdaderos negativos, 0 falsos positivos, 4 falsos negativos y 38 verdaderos positivos.

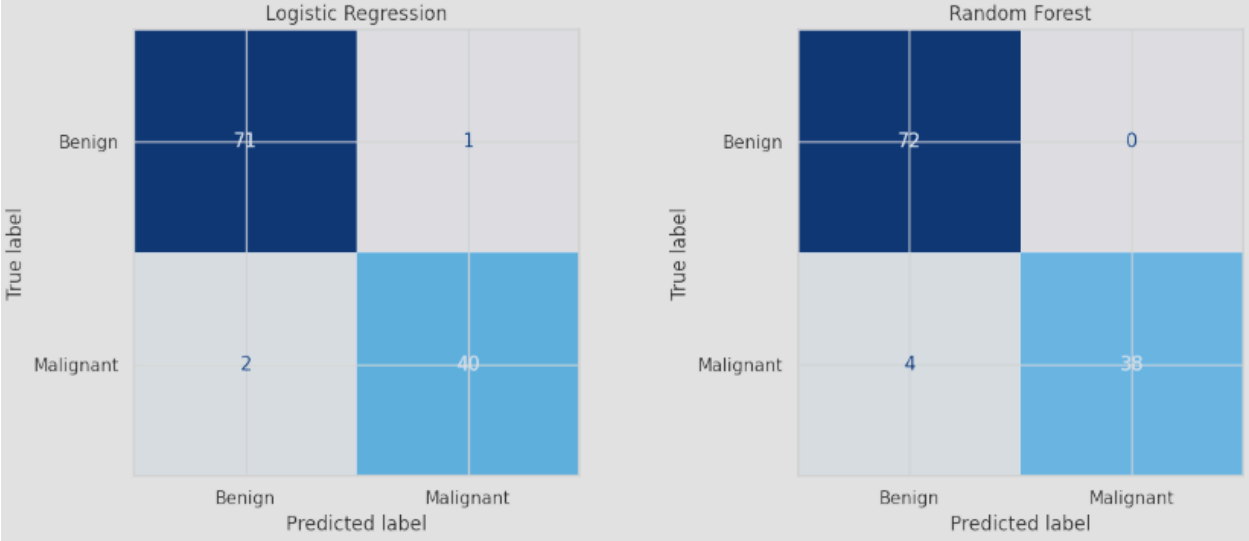


Figura 2. Comparación de matrices de confusión. La regresión logística presentó un menor número de falsos negativos.

A pesar de que Random Forest alcanzó una precisión del 100%, registró cuatro casos malignos clasificados incorrectamente como benignos, frente a dos errores de regresión logística.

En una aplicación hipotética de detección clínica, la reducción de falsos negativos constituye una consideración importante, aunque sería necesario definir formalmente los costos de cada tipo de error y validar el sistema externamente.

La validación cruzada también favoreció descriptivamente a la regresión logística, con una diferencia de aproximadamente 0.0068 en ROC-AUC promedio. No obstante, esta diferencia

no permite establecer superioridad estadística concluyente, ya que los pliegues de validación no representan experimentos completamente independientes.

Por lo anterior, se seleccionó la regresión logística como modelo de referencia para este proyecto académico.

Registro de experimentos y reproducibilidad con MLflow

Se implementó MLflow para garantizar el seguimiento estructurado de los experimentos, utilizando SQLite como sistema de almacenamiento local.

Se creó el experimento Actividad5_Comparacion_Modelos, donde se registraron los parámetros utilizados, las métricas de evaluación, la identificación de cada ejecución y la huella SHA-256 del conjunto de datos.

Los dos modelos quedaron registrados con estado FINISHED, incluyendo sus artefactos de entrenamiento.

Durante la implementación se presentaron dificultades de compatibilidad al guardar inicialmente Random Forest mediante el formato de serialización skops. El problema se resolvió mediante la configuración explícita de los tipos internos autorizados.

Posteriormente, la interfaz gráfica de MLflow no pudo visualizarse directamente en Google Colab debido a restricciones de seguridad relacionadas con el encabezado del proxy (Invalid Host header).

Esta limitación no afectó el almacenamiento de los experimentos. Como alternativa, se utilizaron las funciones de consulta de MLflow para recuperar y exportar los registros a mlflow_runs.csv y mlflow_details.txt.

Asimismo, se archivaron ejecuciones duplicadas realizadas durante la depuración, conservando dos registros activos para la comparación definitiva.

Los scripts, archivos de datos, configuraciones y resultados permiten reproducir el procedimiento bajo un entorno compatible.

Deuda técnica, limitaciones y enfoque MLOps

Aunque los resultados fueron favorables, se identificaron diversas limitaciones técnicas.

El conjunto utilizado es relativamente pequeño y se encuentra previamente depurado, por lo que no representa todas las dificultades de calidad de datos presentes en entornos productivos. Además, se utilizó una única partición de prueba y no se contó con validación externa mediante información procedente de otras instituciones o poblaciones.

También se identificaron dependencias de versiones de bibliotecas, limitaciones del almacenamiento temporal de Colab y la necesidad de estudiar con mayor profundidad la calibración de probabilidades y los posibles sesgos del modelo.

Desde una perspectiva MLOps, se proponen las siguientes mejoras:

- **Automatización:** implementar pruebas de calidad de datos y validaciones de código mediante integración continua.
- **Reproducibilidad:** fijar versiones de dependencias y fortalecer el versionamiento de datos, modelos y configuraciones.
- **Validación estadística:** incorporar intervalos de confianza mediante bootstrap y evaluar el desempeño en conjuntos externos.

- **Optimización de decisiones:** ajustar los umbrales de clasificación considerando los costos asociados con falsos negativos y falsos positivos.
- **Monitoreo:** implementar mecanismos para identificar cambios en las distribuciones de datos, degradación de métricas y necesidad de reentrenamiento.
- **Gobernanza:** establecer controles de seguridad, trazabilidad y evaluación de sesgos antes de considerar cualquier implementación real.

Estas acciones permitirían evolucionar de un experimento académico reproducible hacia un proceso de aprendizaje automático con mayores garantías de calidad y mantenimiento.

Conclusiones

La actividad permitió integrar satisfactoriamente las principales etapas de un flujo de aprendizaje automático: preparación y versionamiento de datos, análisis exploratorio, entrenamiento, optimización de hiperparámetros, evaluación comparativa y registro de experimentos con MLflow.

Los dos algoritmos mostraron un desempeño elevado. Sin embargo, la regresión logística presentó mejores métricas generales y una menor cantidad de falsos negativos, motivo por el cual fue seleccionada como modelo de referencia.

El registro mediante MLflow permitió conservar parámetros, métricas y artefactos de manera estructurada, demostrando la importancia de la trazabilidad y la reproducibilidad dentro de proyectos de inteligencia artificial.

Finalmente, se identificó que obtener métricas elevadas no garantiza que un modelo esté preparado para producción. La validación externa, la gestión de dependencias, el monitoreo

continuo y el análisis de riesgos son componentes indispensables para una implementación responsable.

Los resultados deben interpretarse exclusivamente dentro del contexto experimental y no como evidencia de utilidad clínica.

Referencias

Scikit-learn. (s. f.). Breast cancer Wisconsin (diagnostic) dataset. Documentación oficial de scikit-learn.

UCI Machine Learning Repository. (s. f.). Breast Cancer Wisconsin (Diagnostic).

MLflow. (s. f.). MLflow Tracking. Documentación oficial de MLflow.